让技术文献成为可追溯的知识资产

DeepDocParse

面向技术文献的
多模态 PDF 知识工作台

从“找一段文字”，到组织可回查、
可复核、可持续修订的知识。

Web 工作台 / Electron 桌面 / MCP 接口



一套资料，支撑五类研读与复用任务

输入资料

公开论文
M3-Embedding 固定 v5

技术手册
Pico / ESP32 等历史样例

文献知识处理链
固定版本与原文证据
连接检索和生成任务

全文与跨文档检索
按授权资料范围查找证据

带出处问答
主张逐项连接原文

结构化抽取
按 Schema 生成字段结果

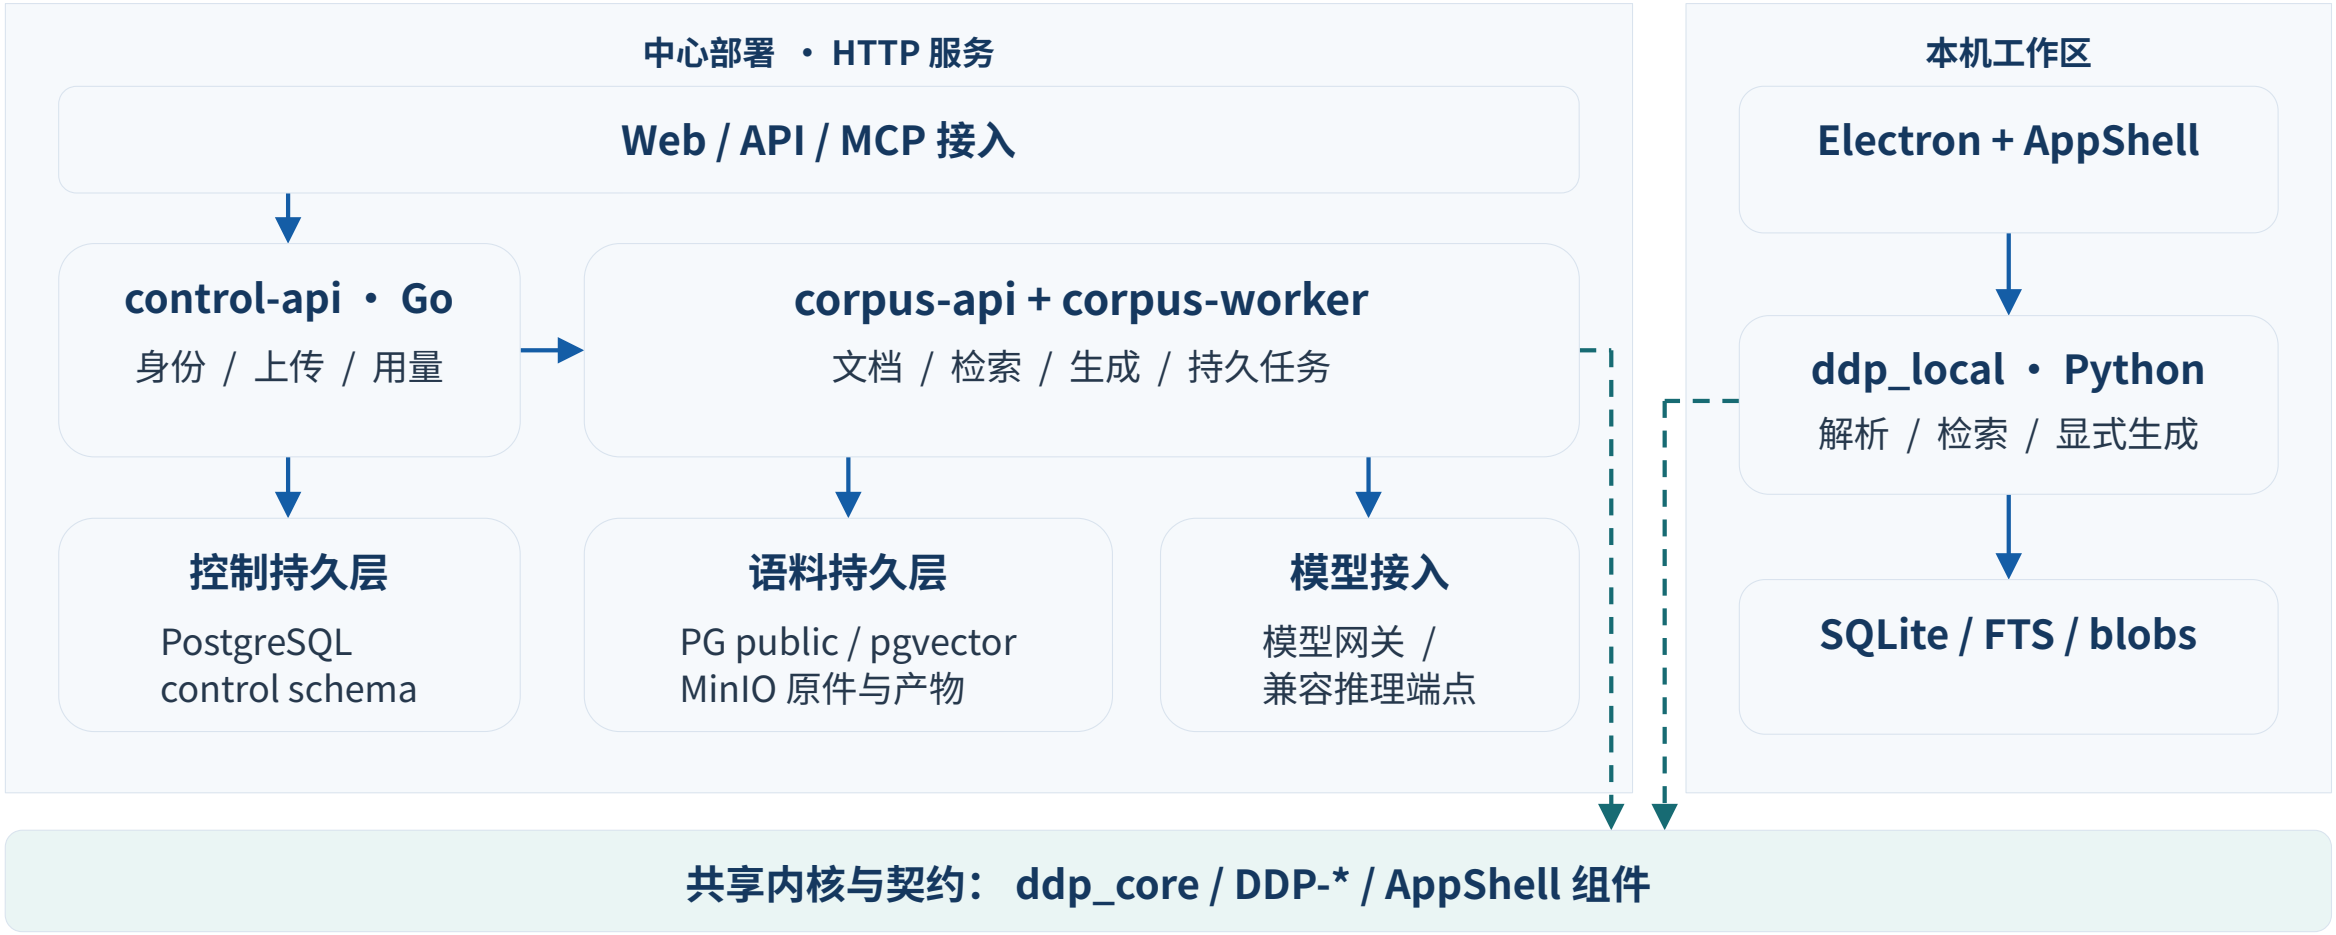
知识 Wiki
组织主题、依赖与修订

证据回查
回到同版 PDF 页与区域

独立验证集

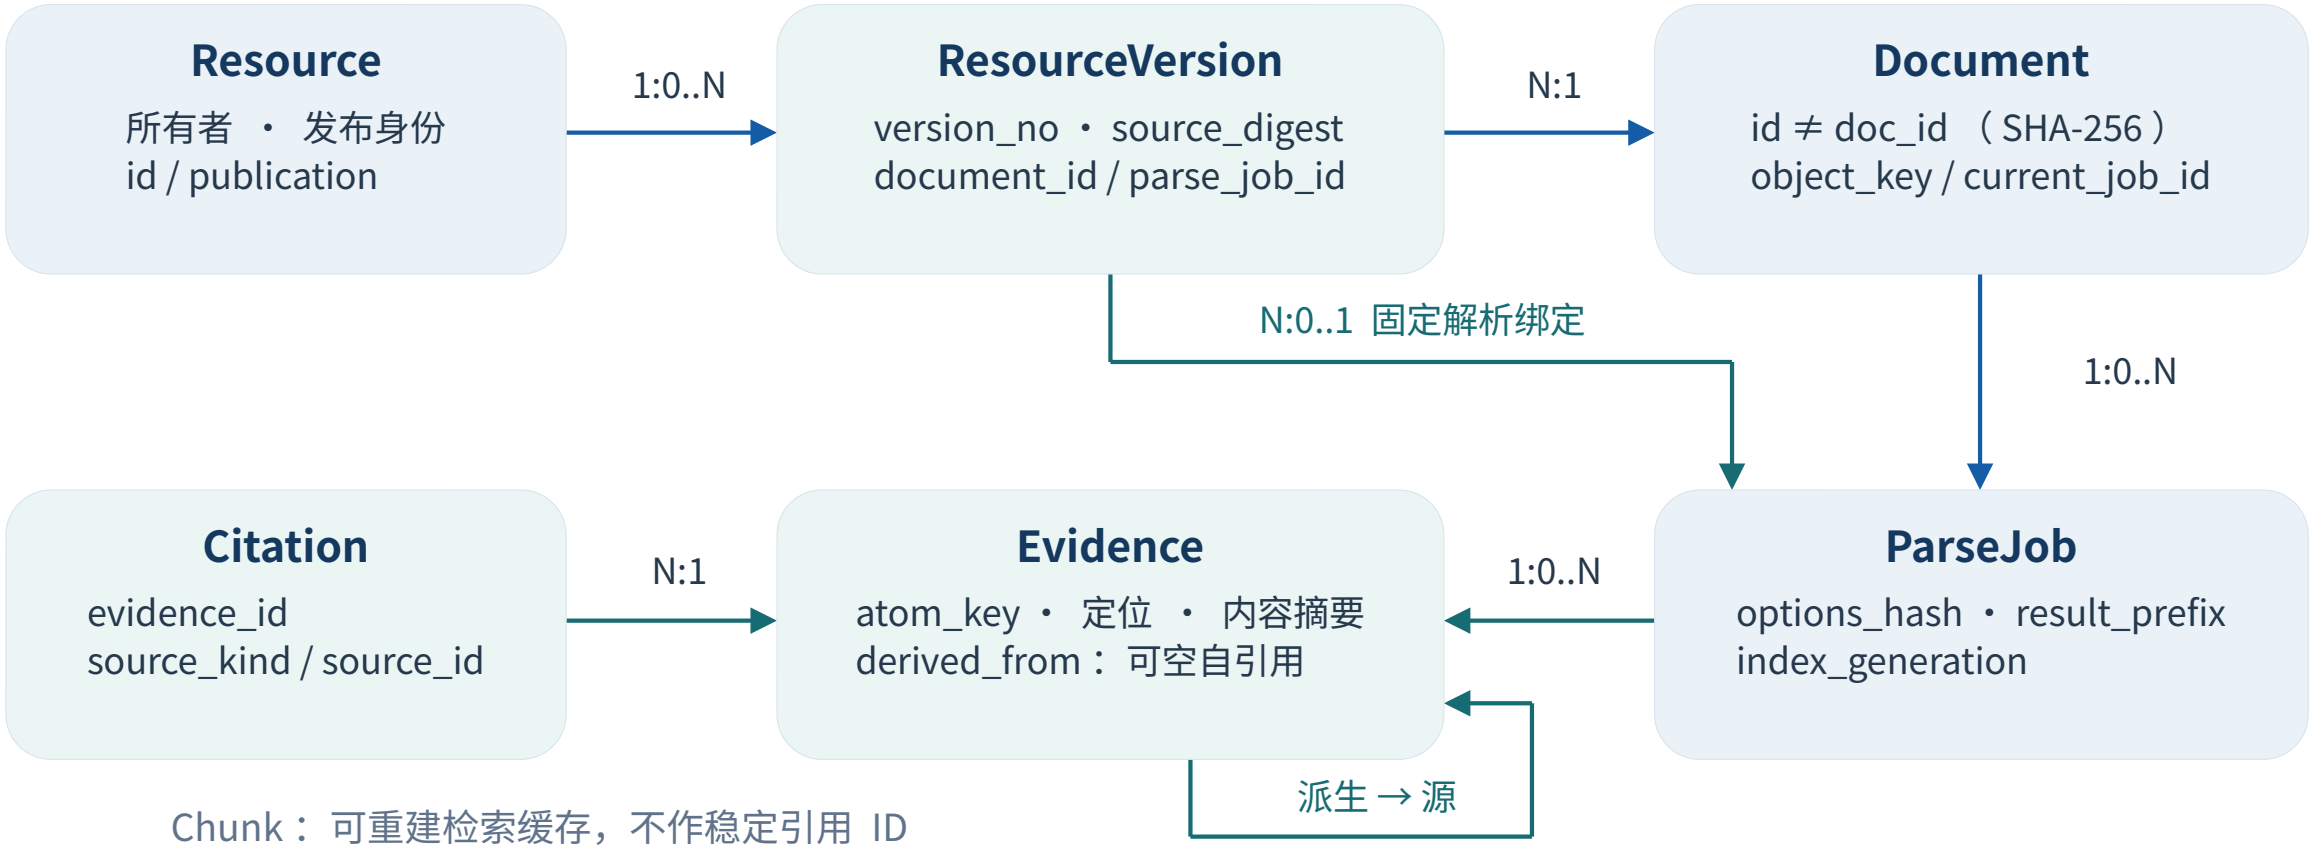
QASPER 人类参考题集 → 问答 / 证据对照评测
验证数据与用户资料分开管理。

总体架构：中心服务与本机工作区共用内核



核心机制 · 资料身份

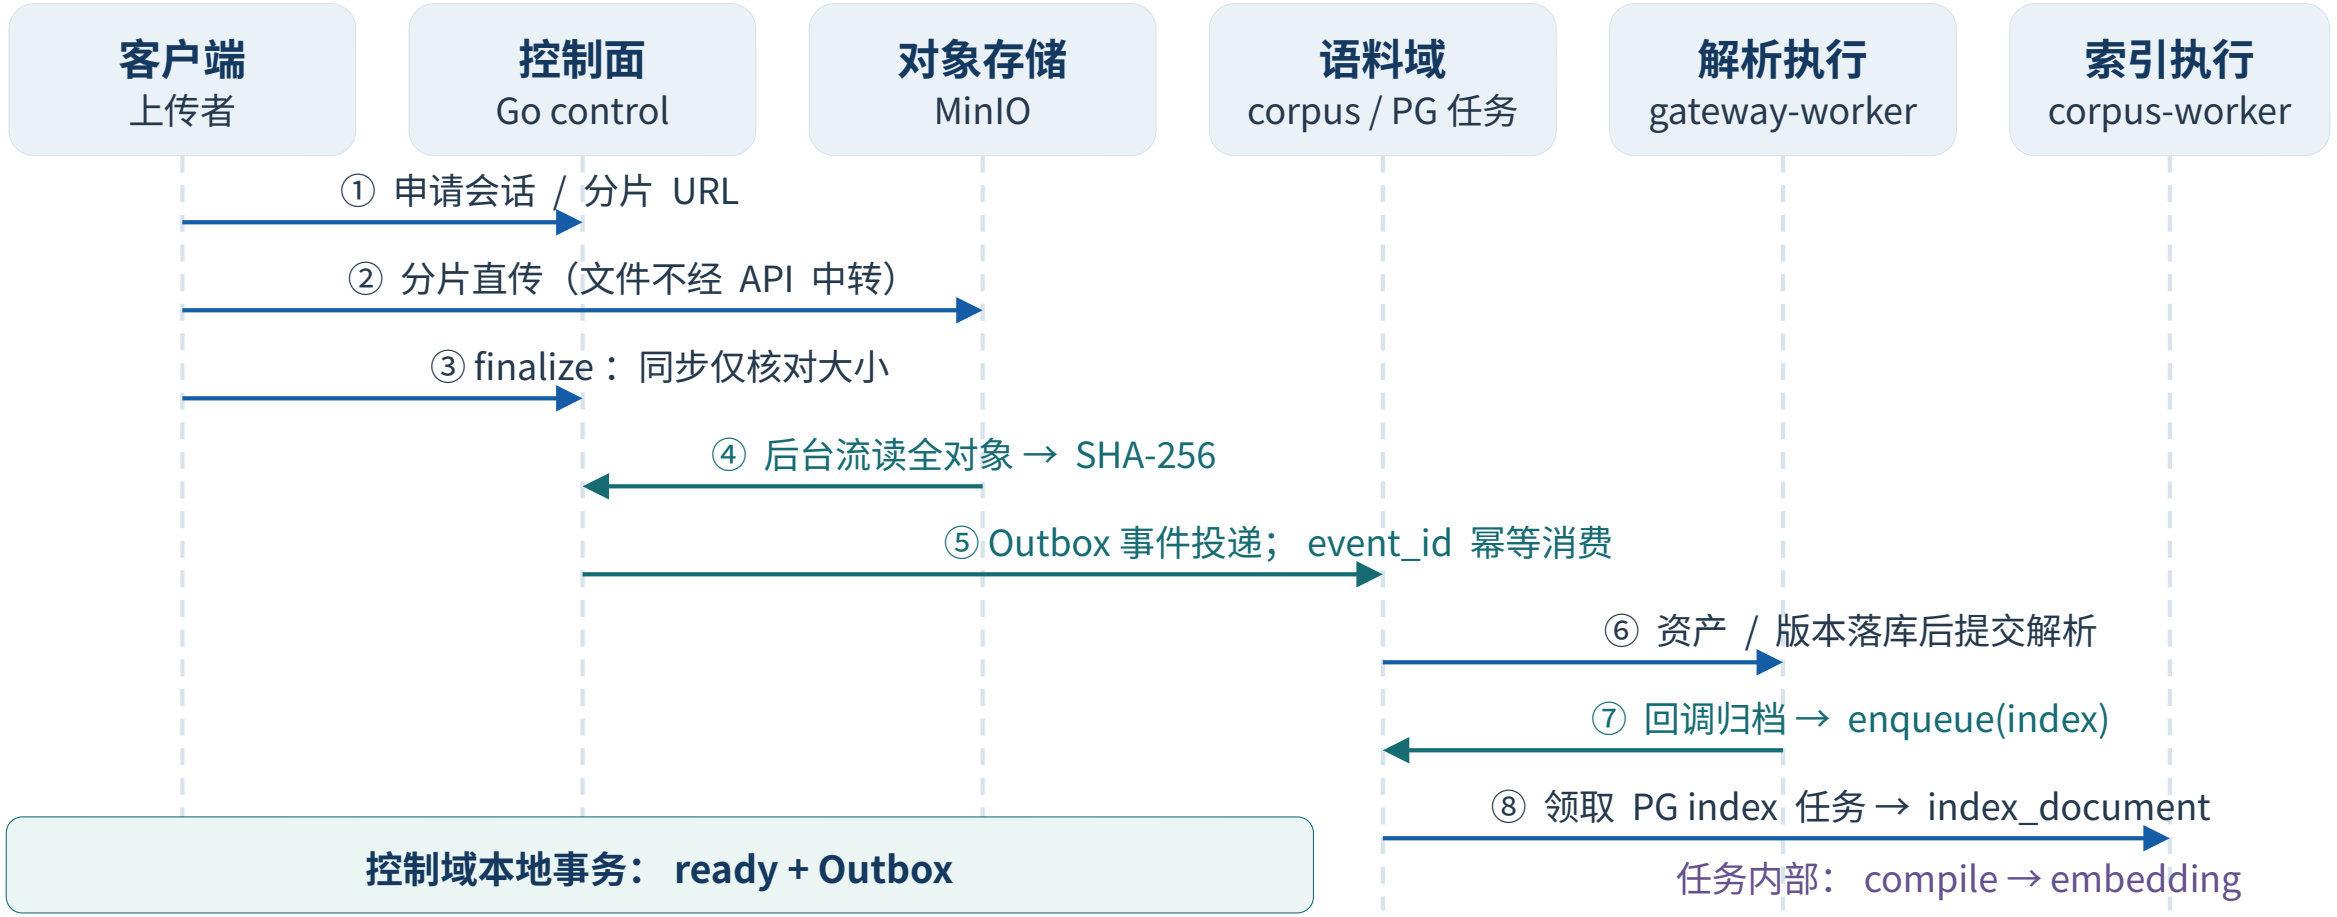
从逻辑资源到稳定证据



Chunk：可重建检索缓存，不作稳定引用 ID

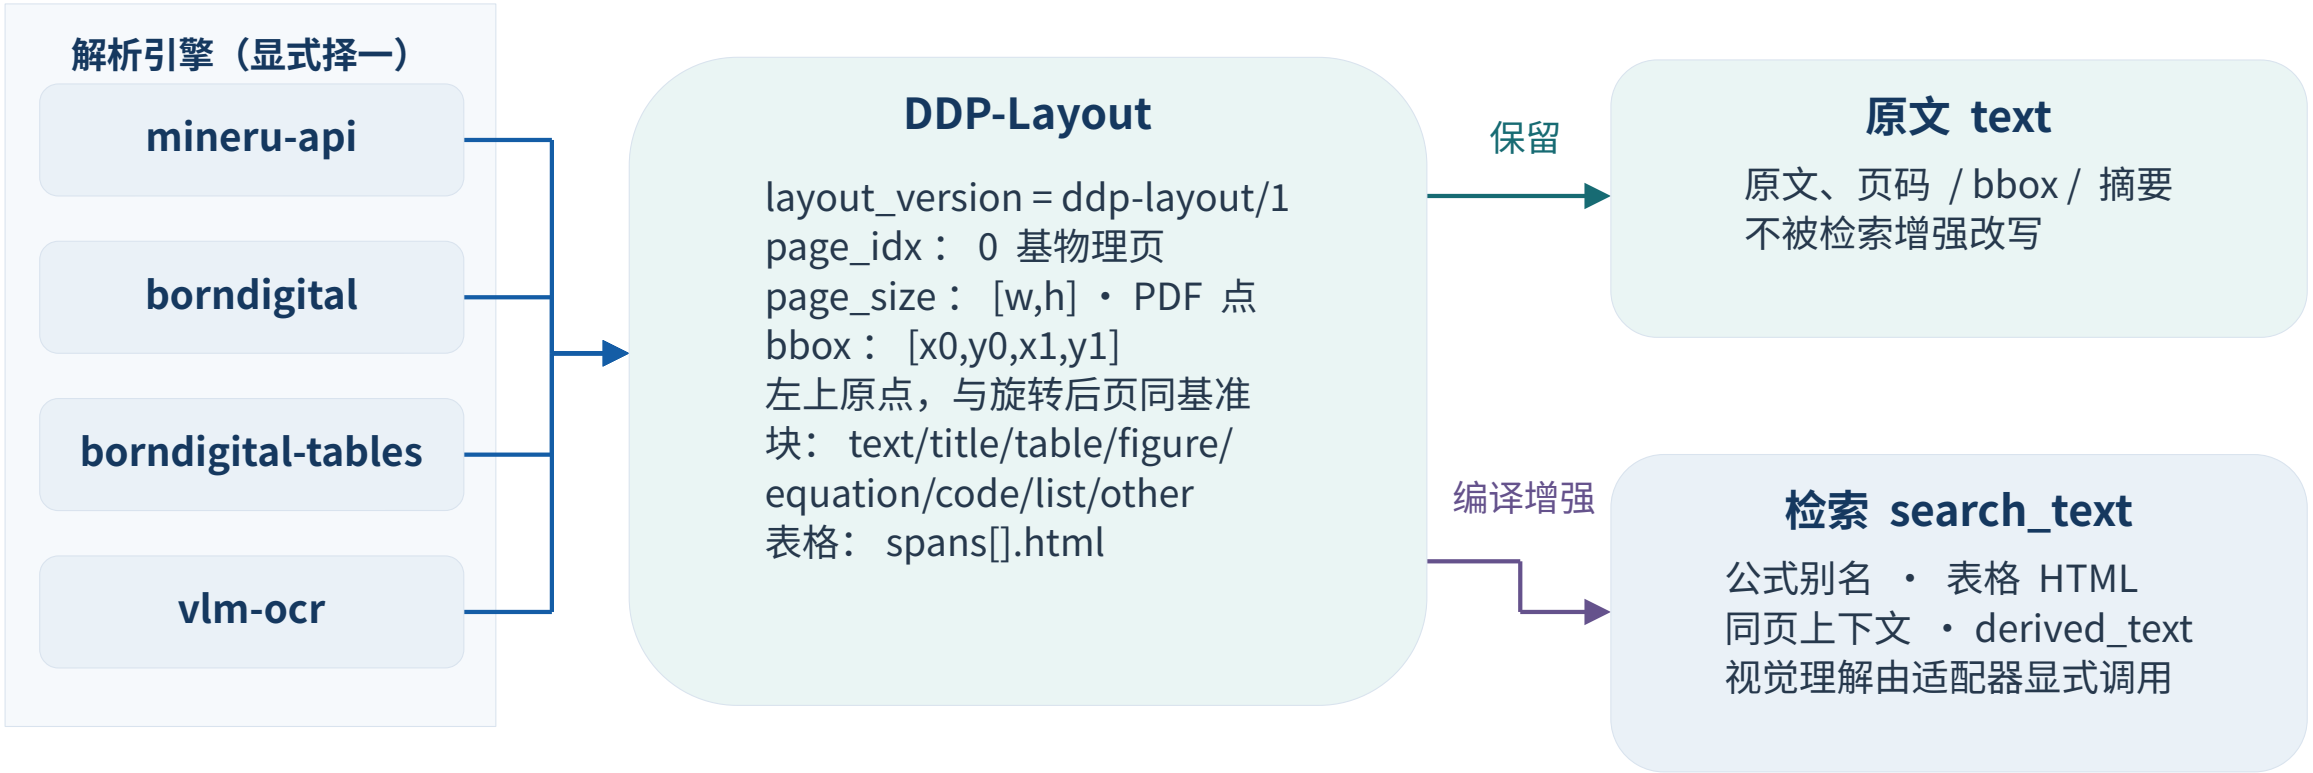
核心机制 · 接入时序

文件入库：摘要核验与异步编译索引



核心机制 · 多模态解析

统一布局，分离原文与检索增强

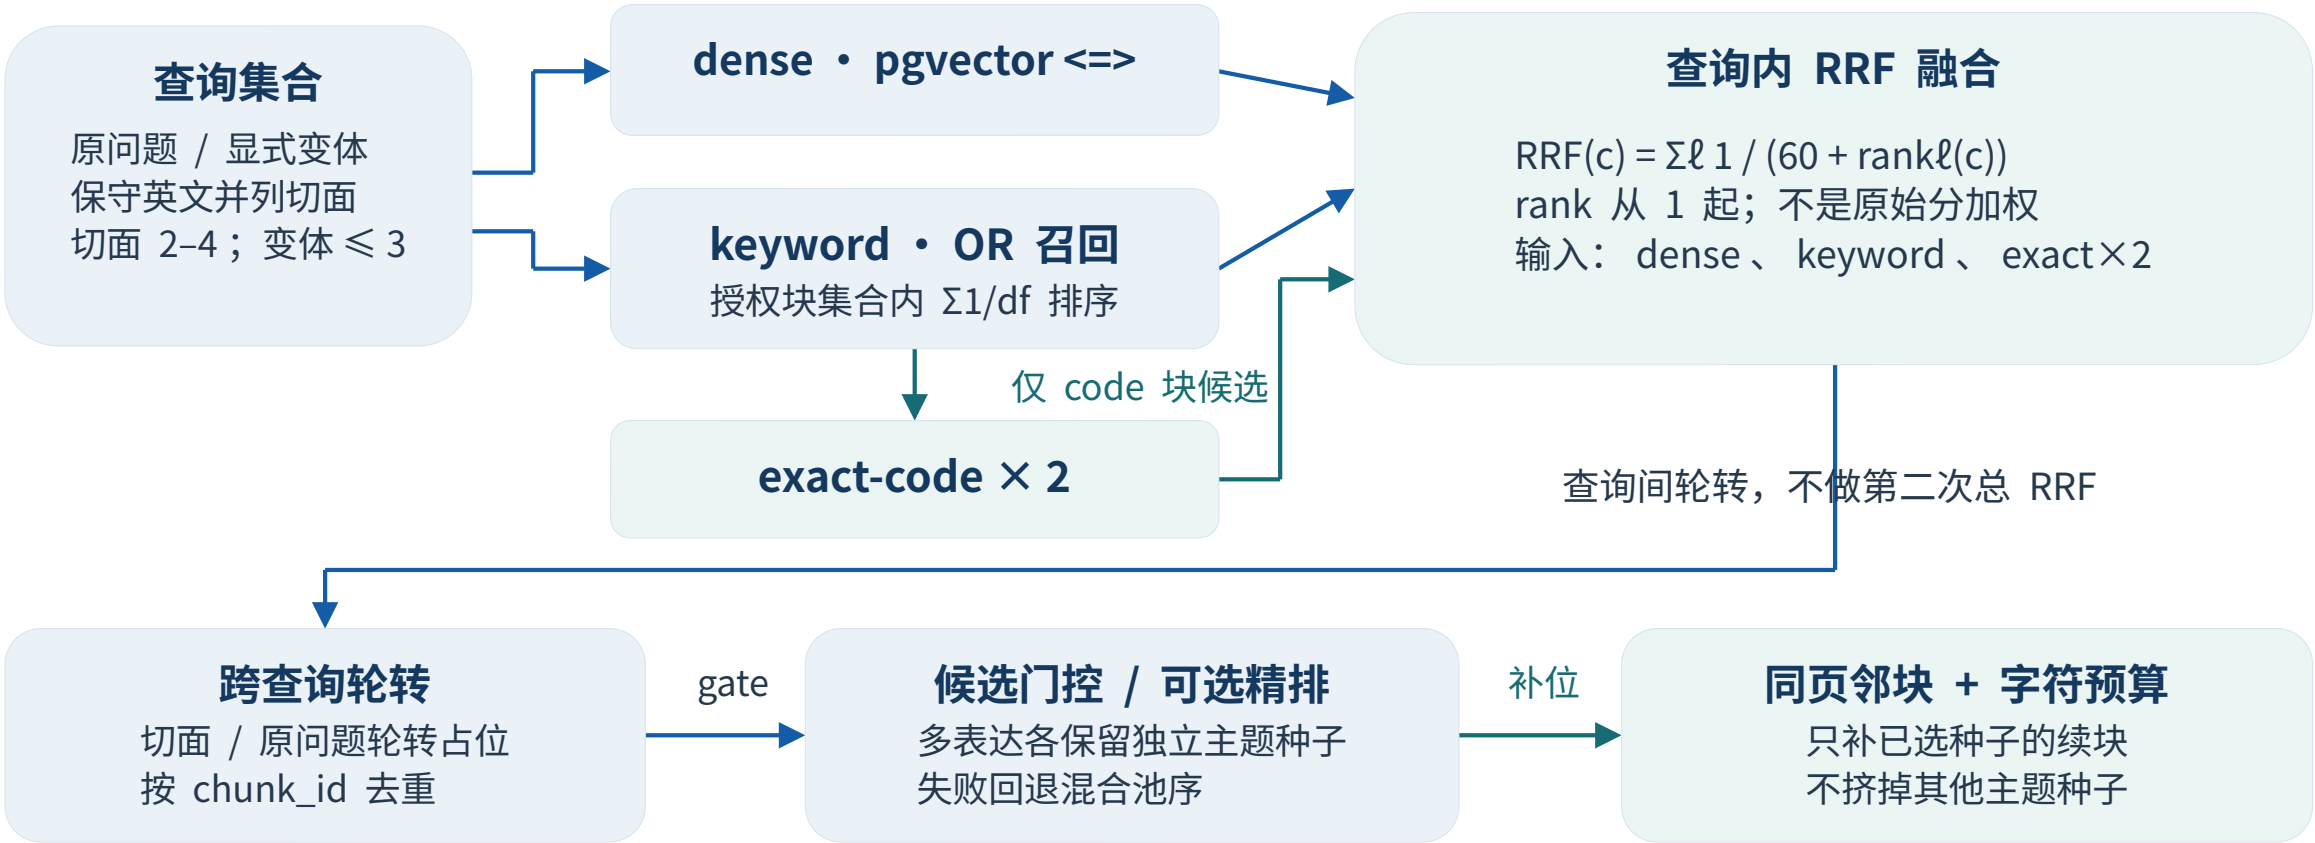


定位贯穿编译与索引；长块切分可继承块框，不承诺句子级精确框。

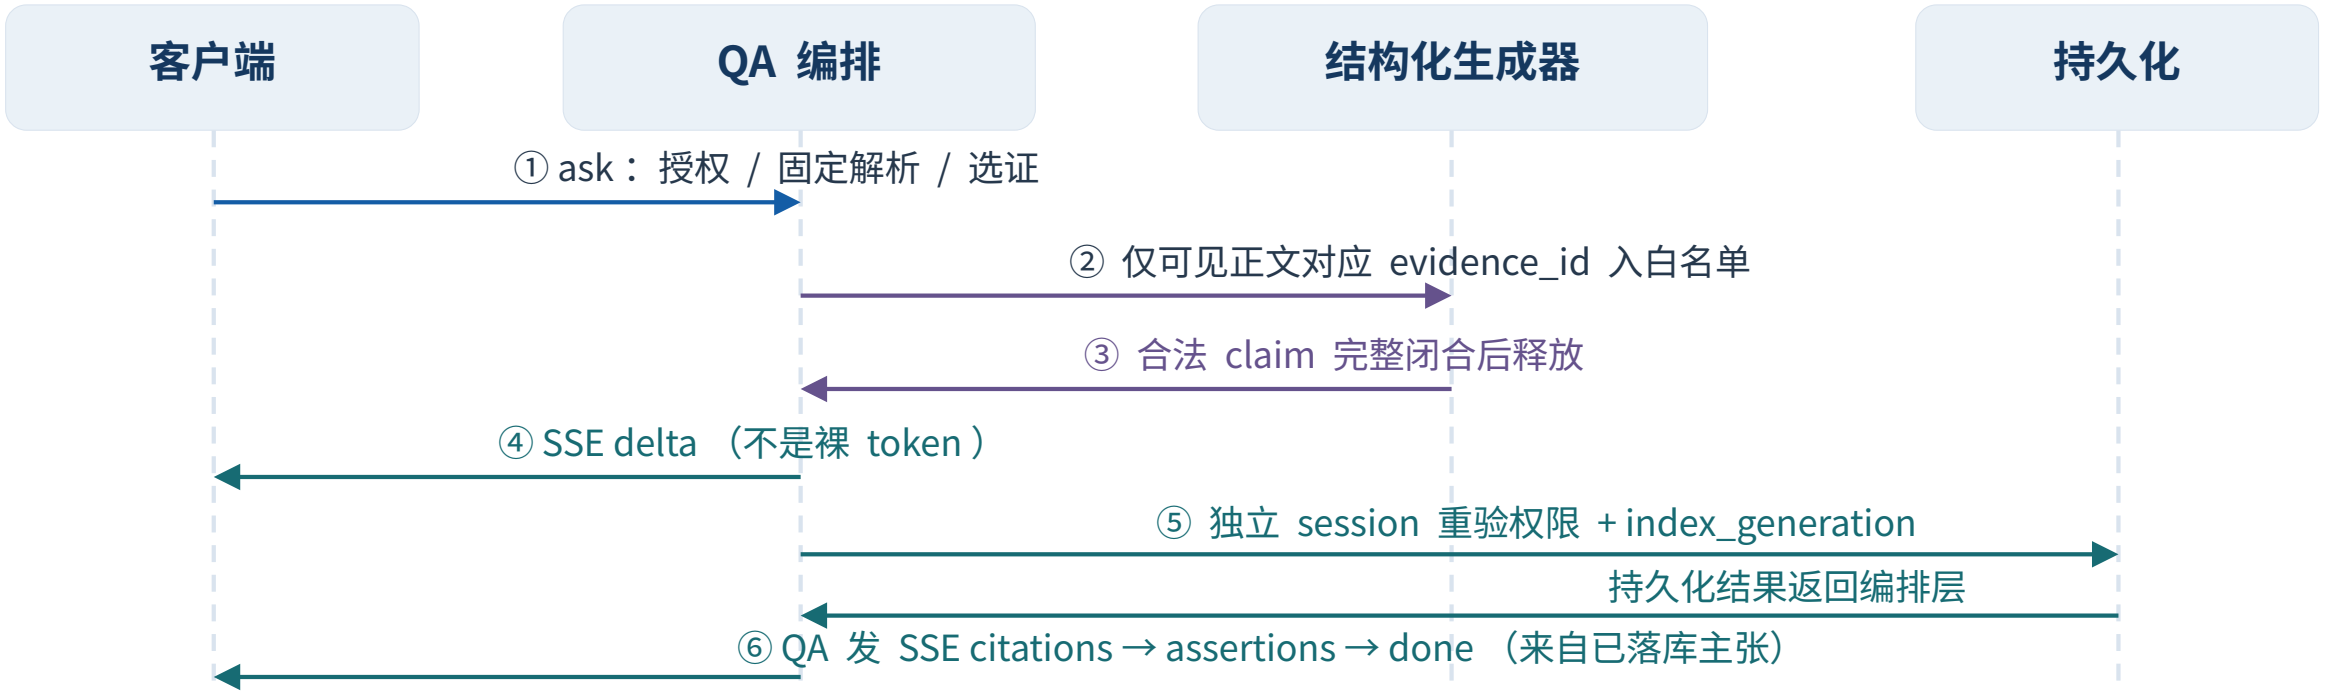
核心机制 · 混合检索

按名次融合，给每个问题切面留位

召回范围：仅授权 document_id / parse_job_id ； 此处为中心索引实现。



完整主张闭合后，才进入答案流

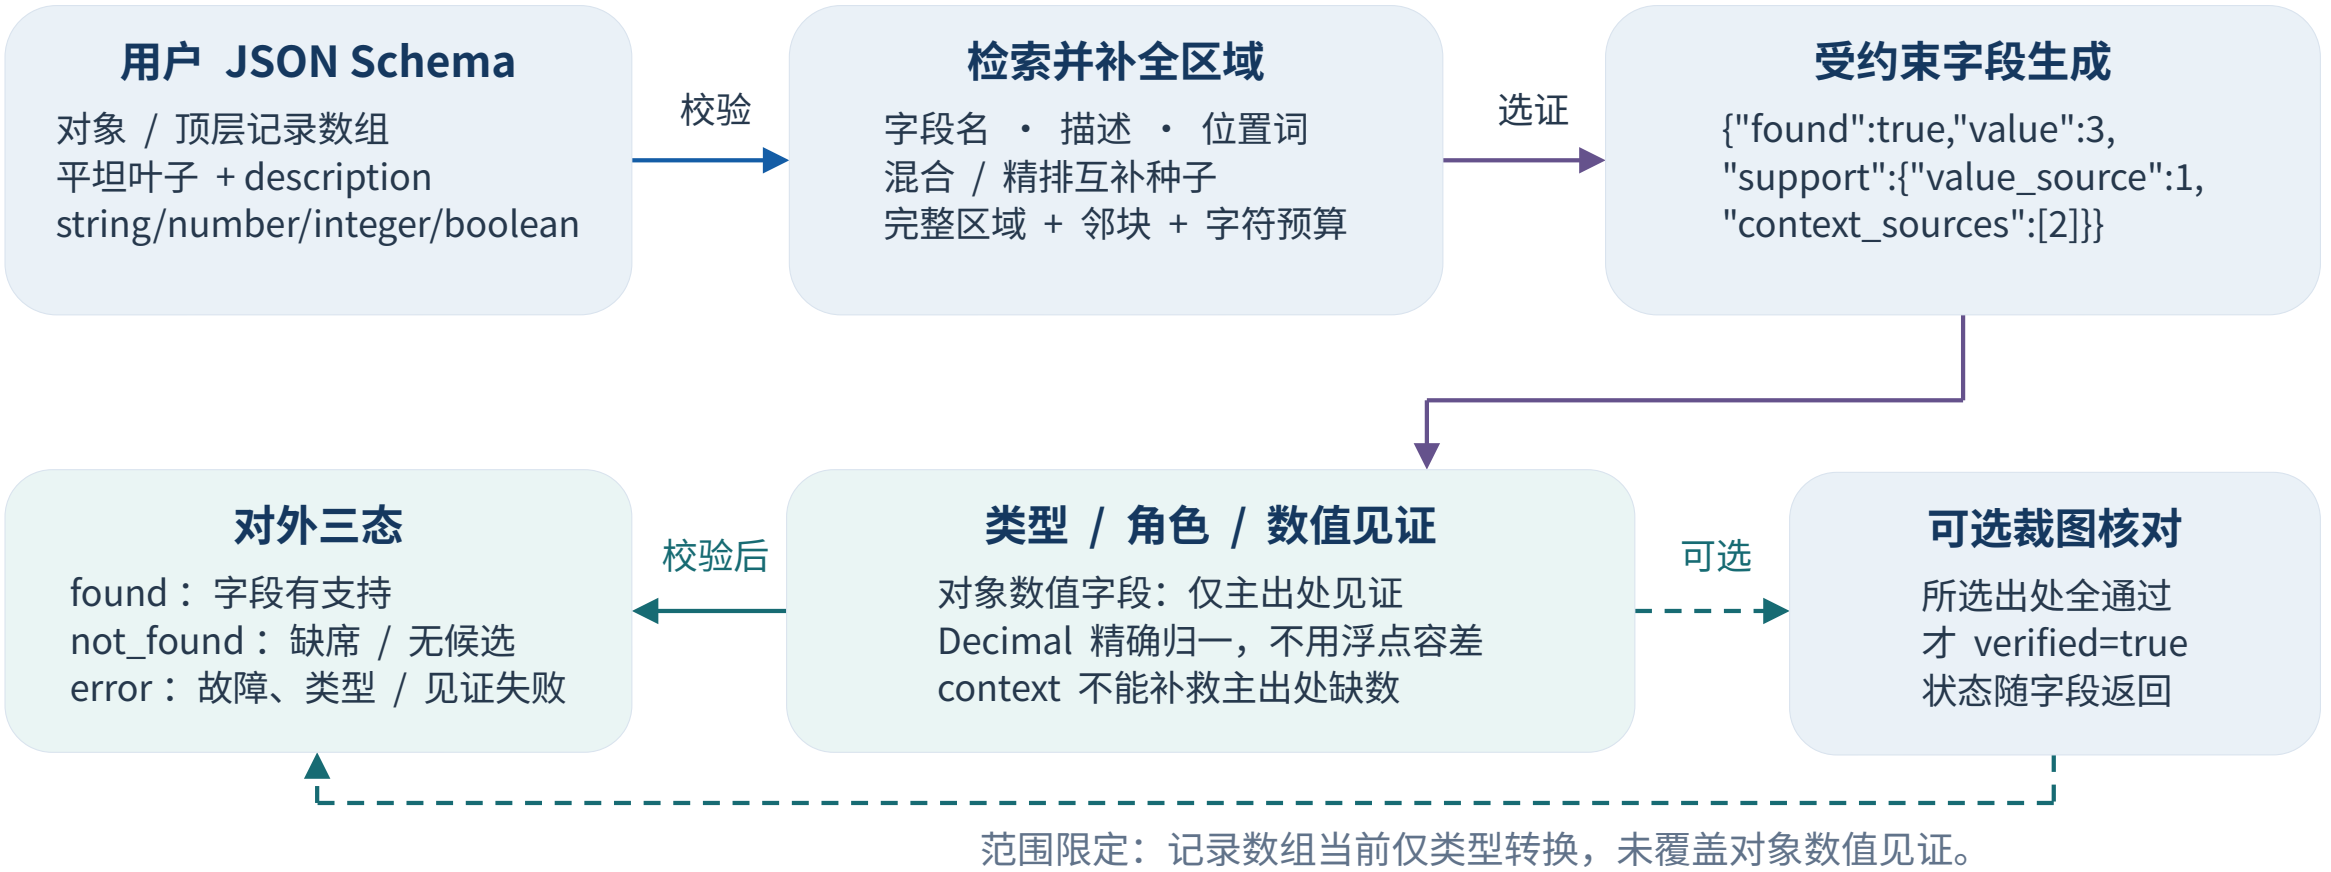


生成器线协议示例（不返回 status / verified ）

{"claims":[{"text":" 额定电压是 220 V 。 ","evidence_ids":["evidence-id"]}],
"unanswered":[]}

核心机制 · 结构化抽取

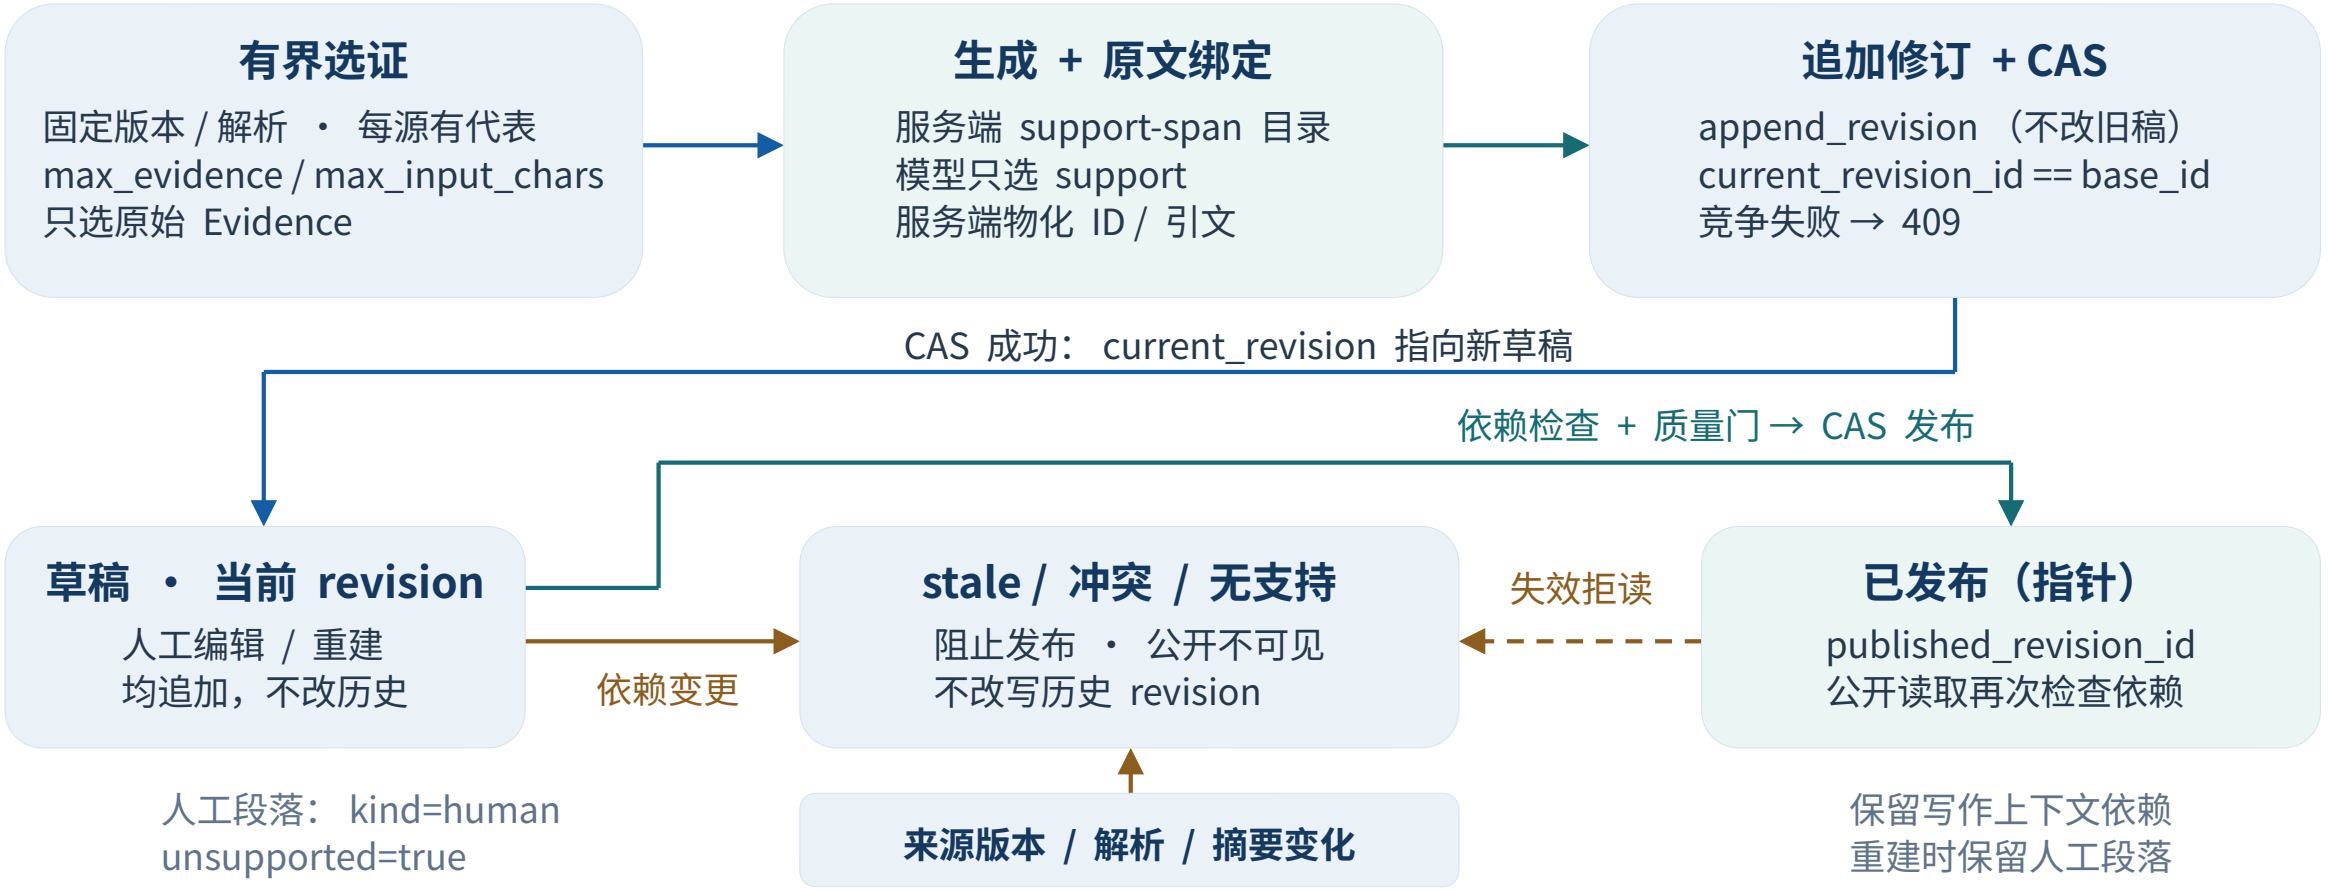
字段带出处，数值有主出处见证



范围限定：记录数组当前仅类型转换，未覆盖对象数值见证。

核心机制 · Wiki 修订

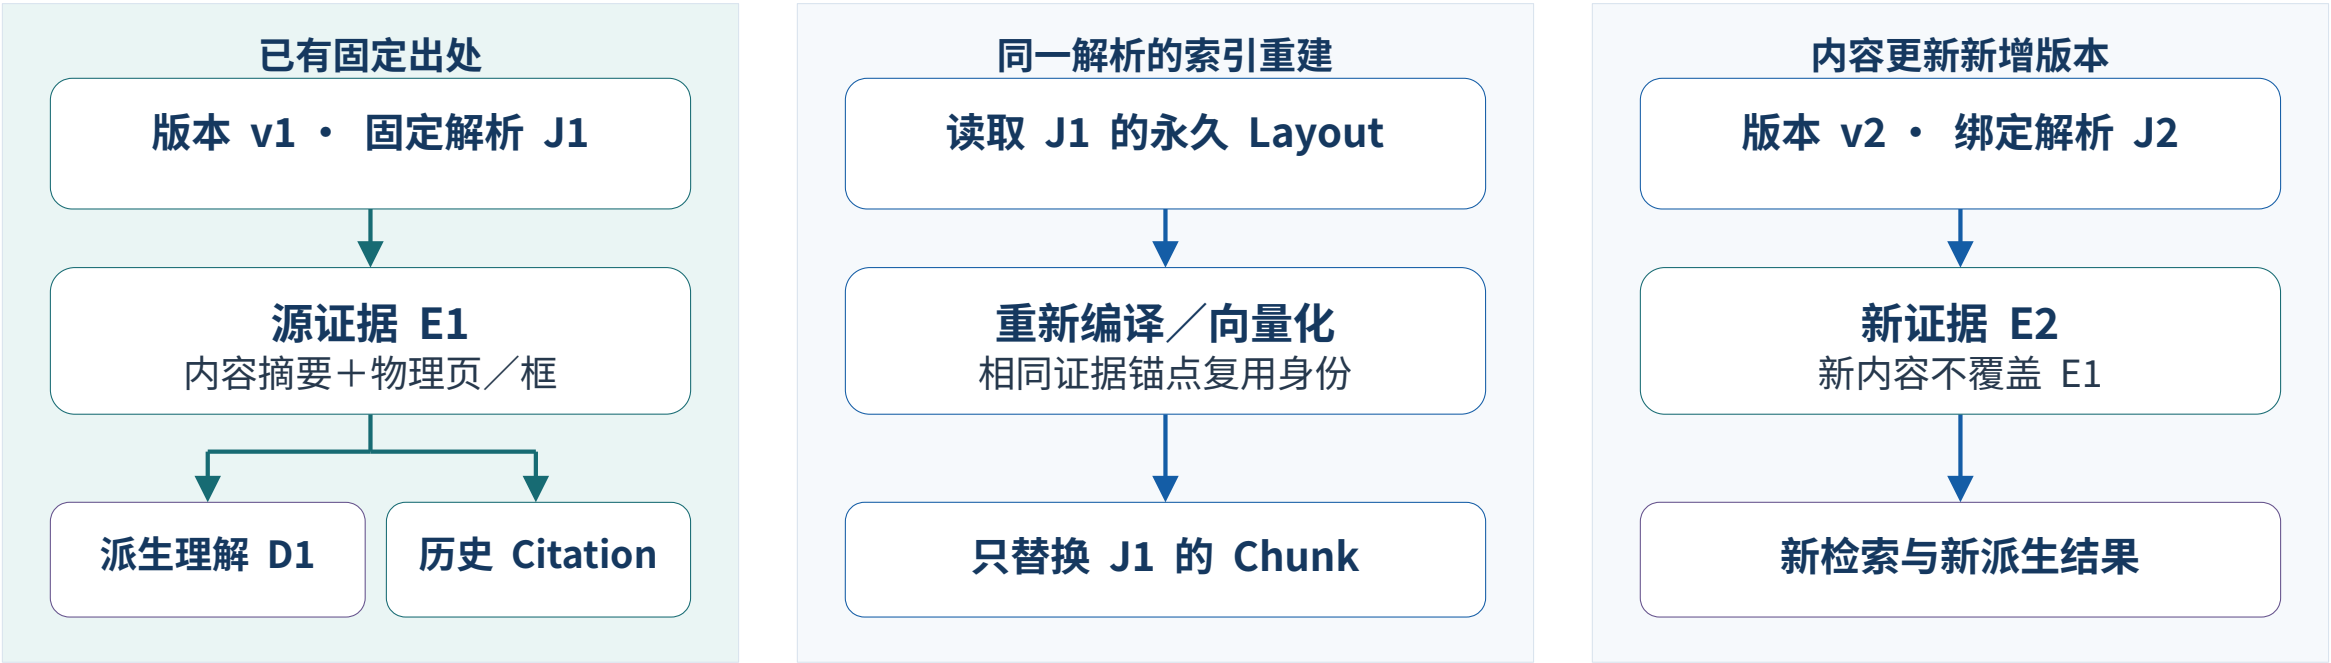
先冻结证据，再追加可回溯修订



可追溯与可更新

更新索引，不让旧引用换了出处

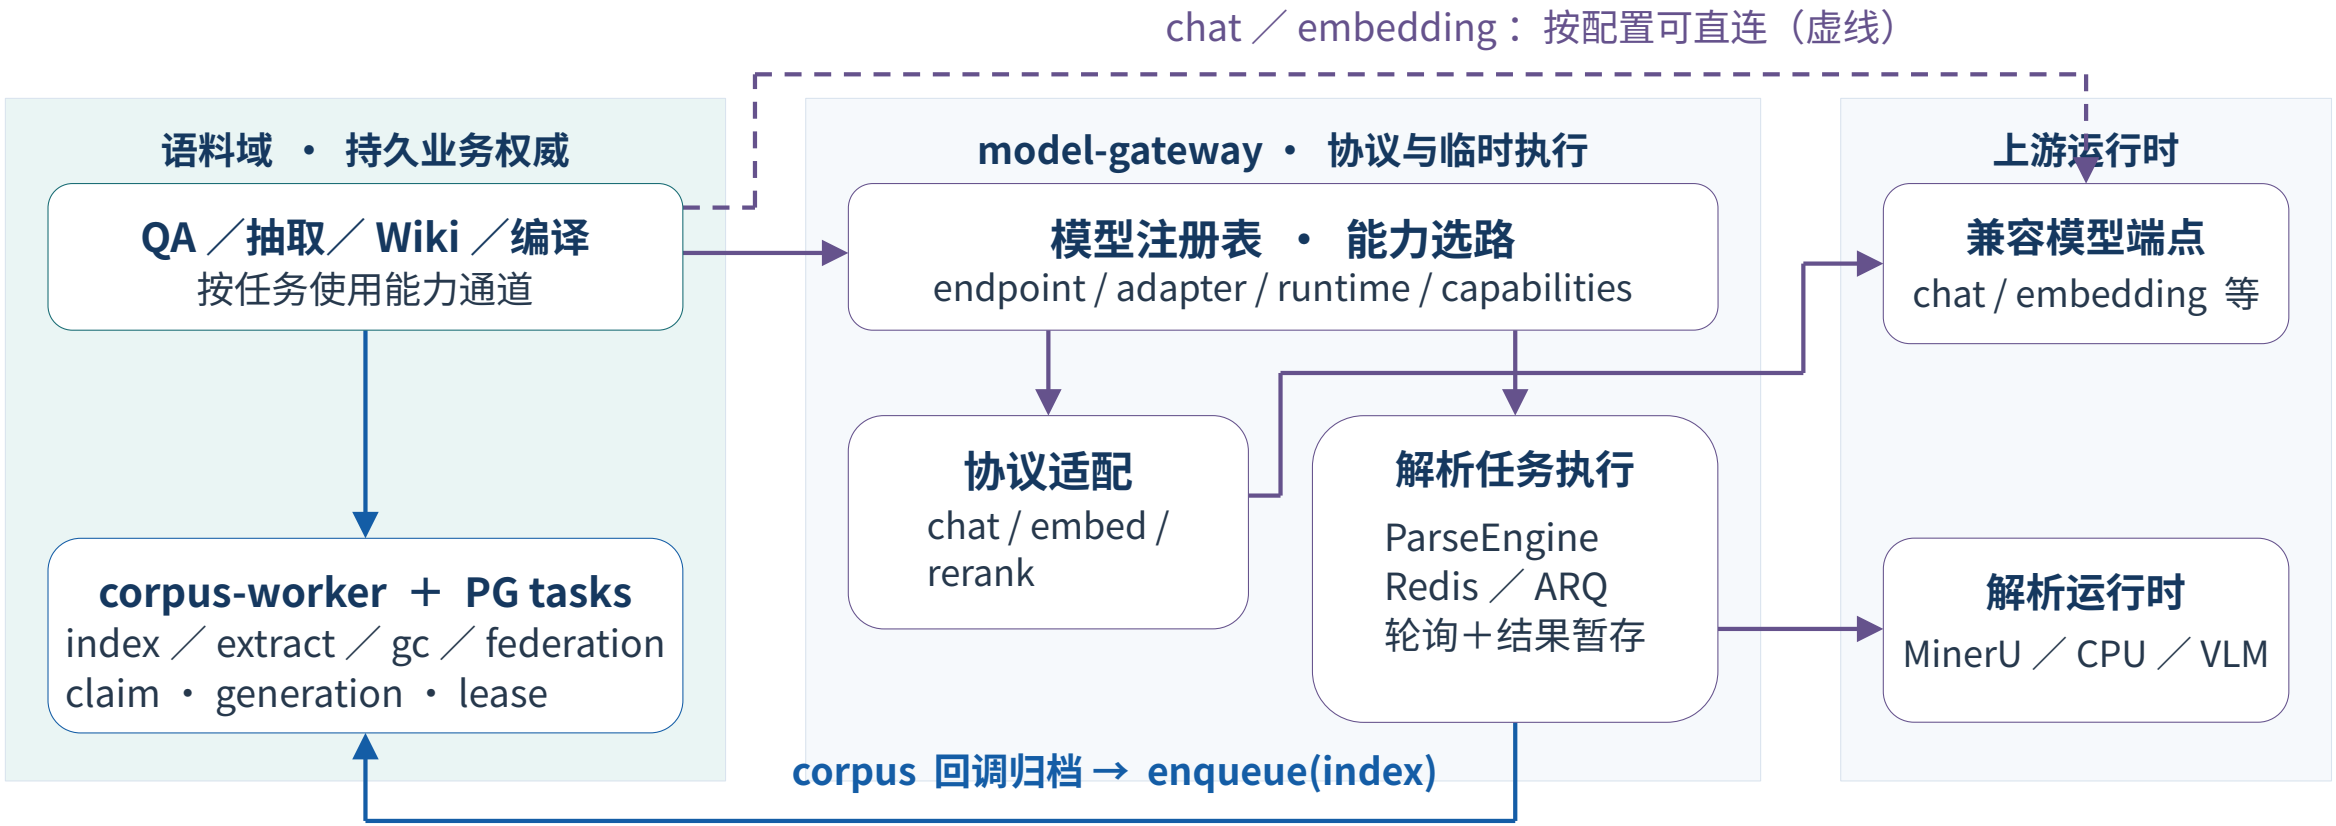
保留过去 → 重建检索缓存 → 追加新状态



稳定身份留在 Evidence； Chunk 可重建，依赖变化使 Wiki 等派生结果标记 stale 。

能力路由与任务执行

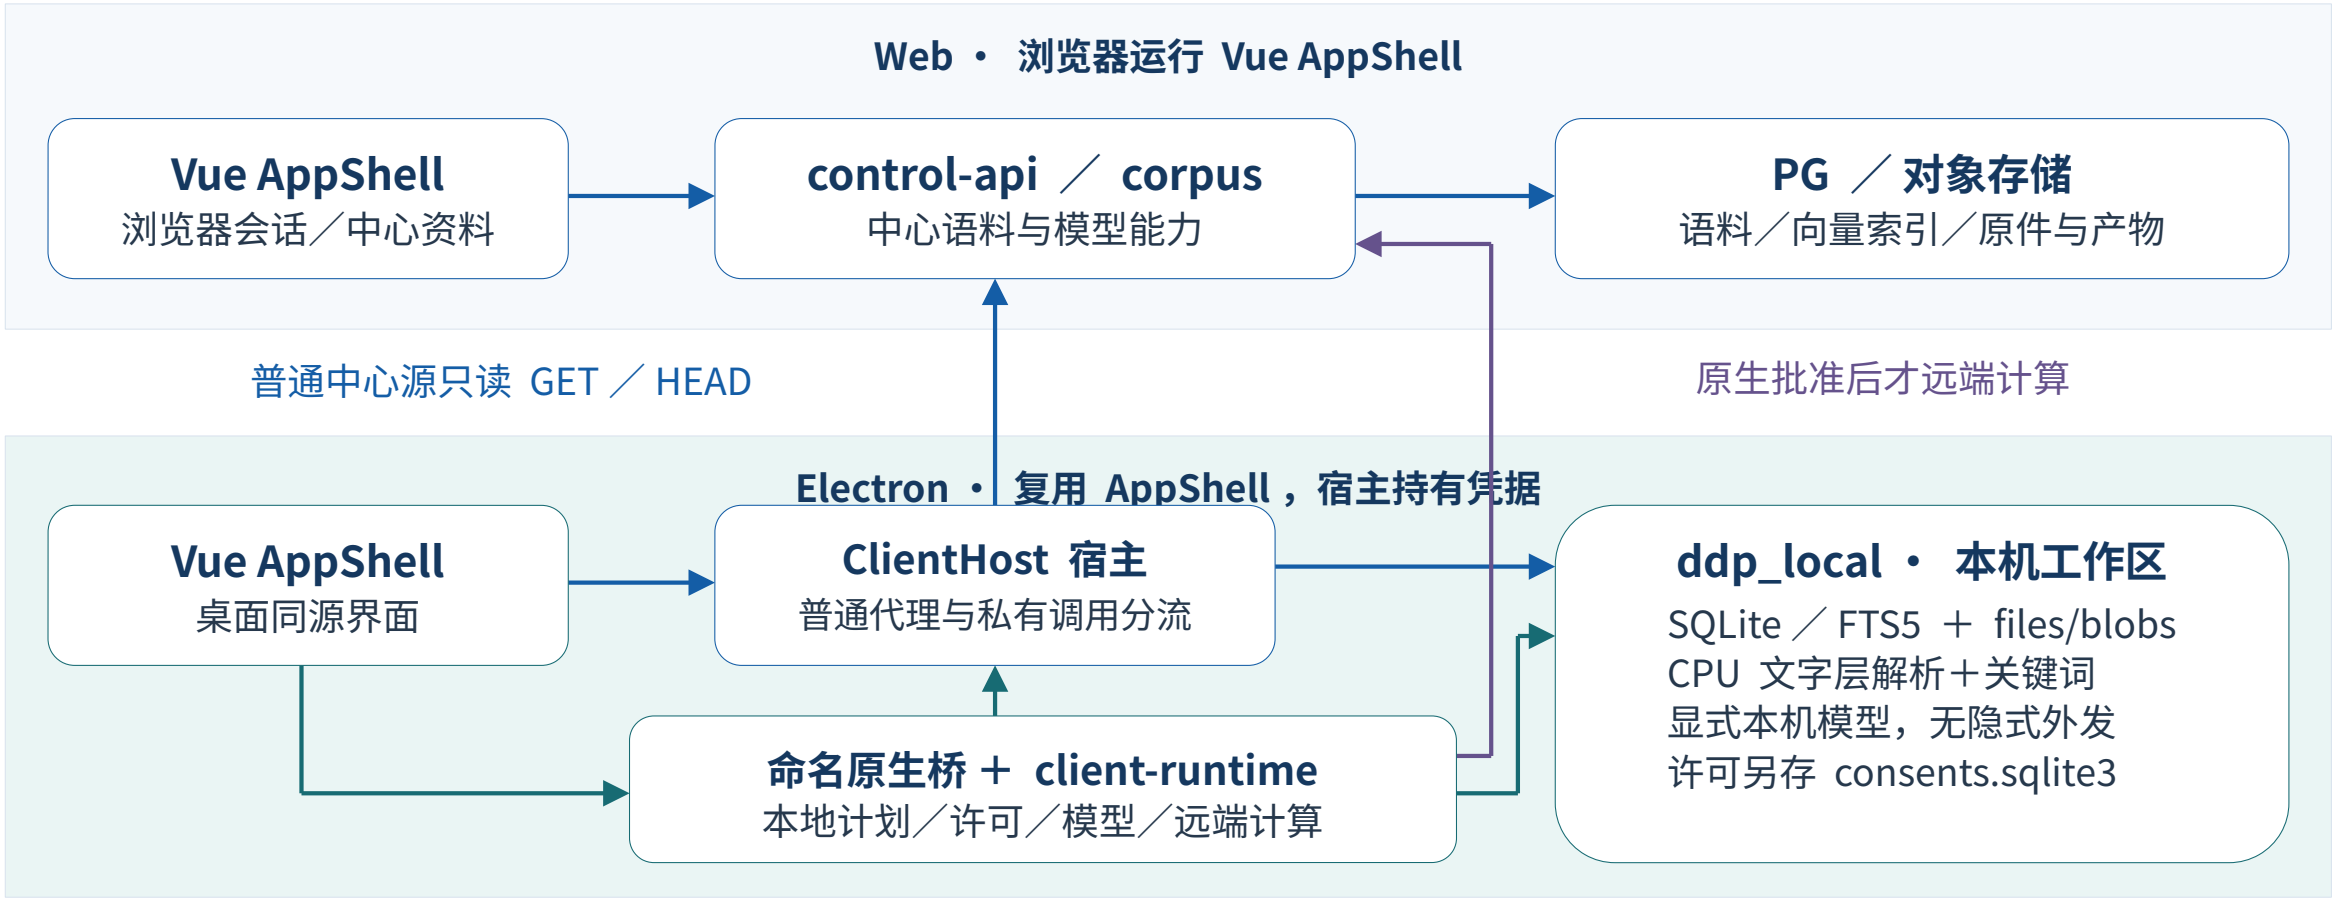
模型能力适配，业务状态各有所属



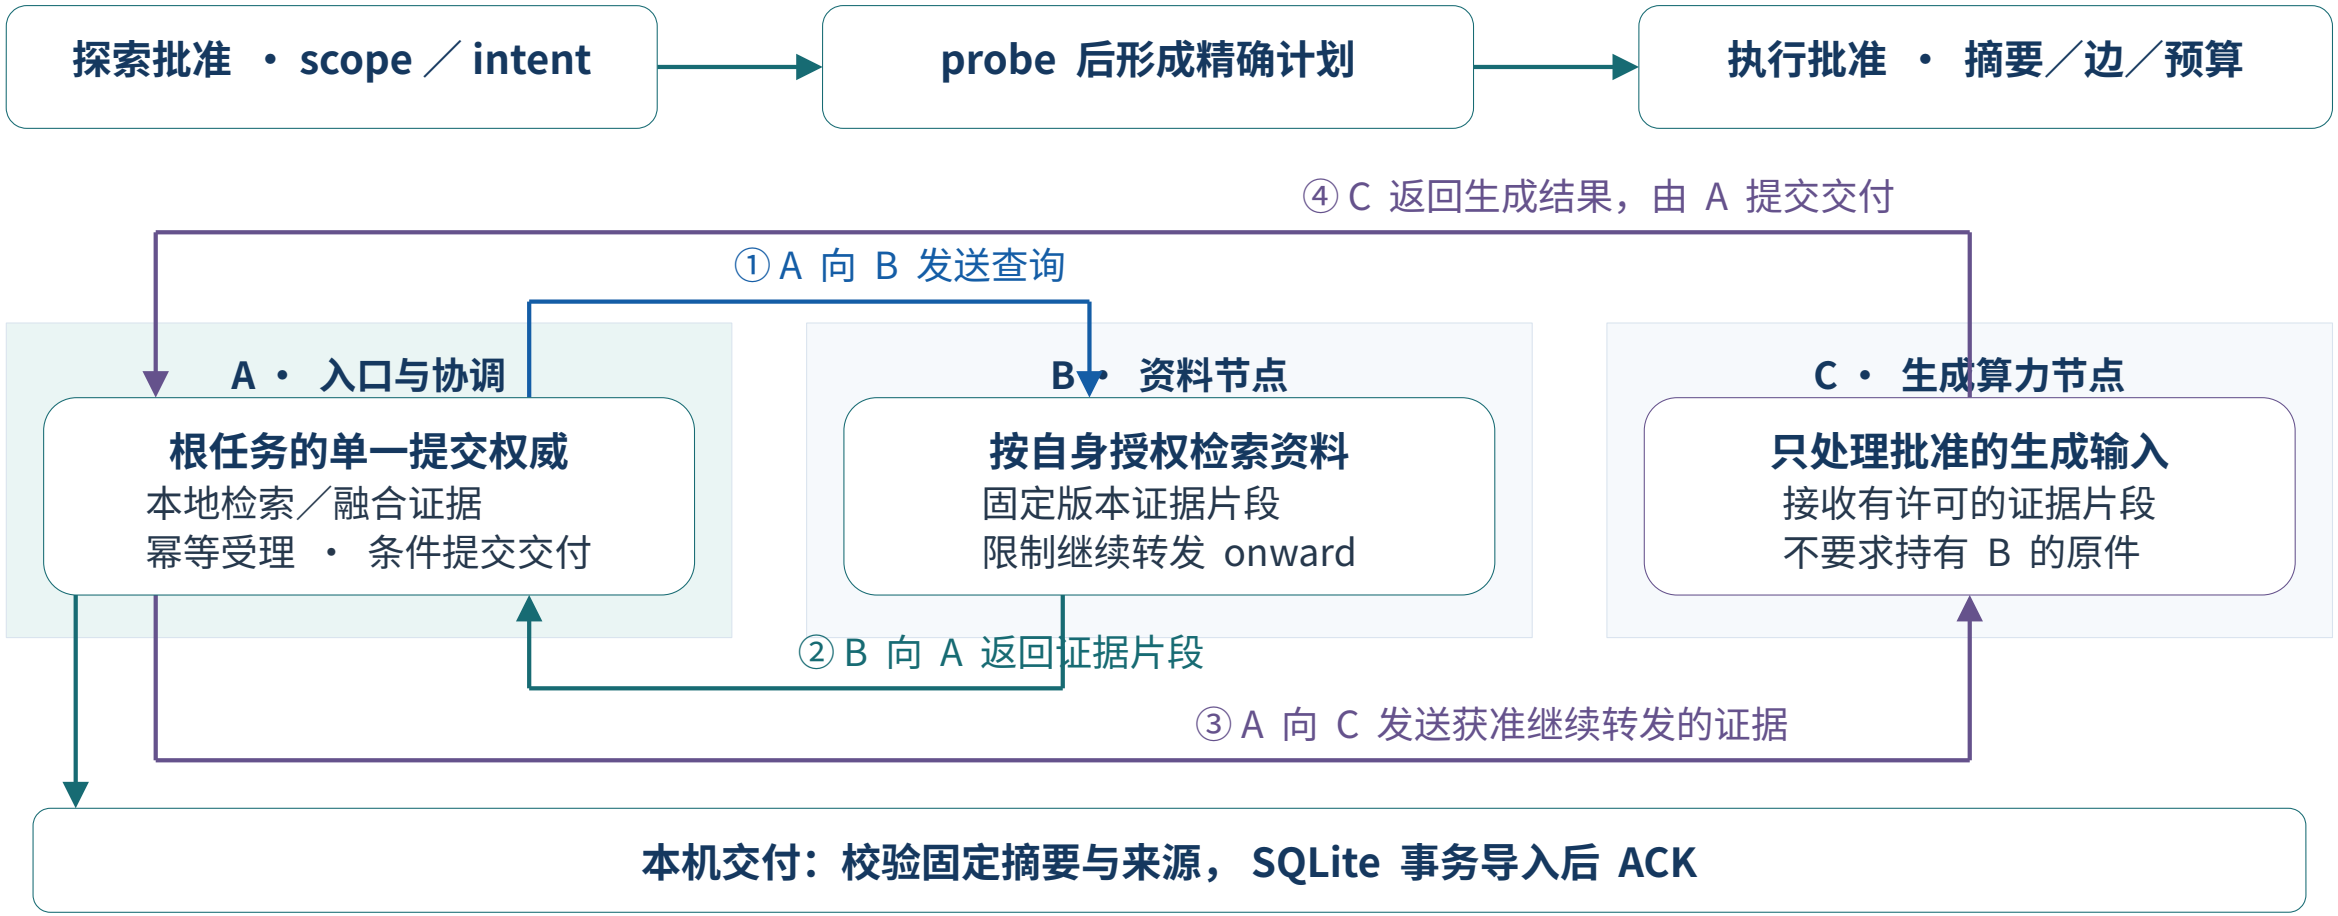
解析回调归档后排 index；永久语料索引与网关临时结果分开。

双端与执行位置

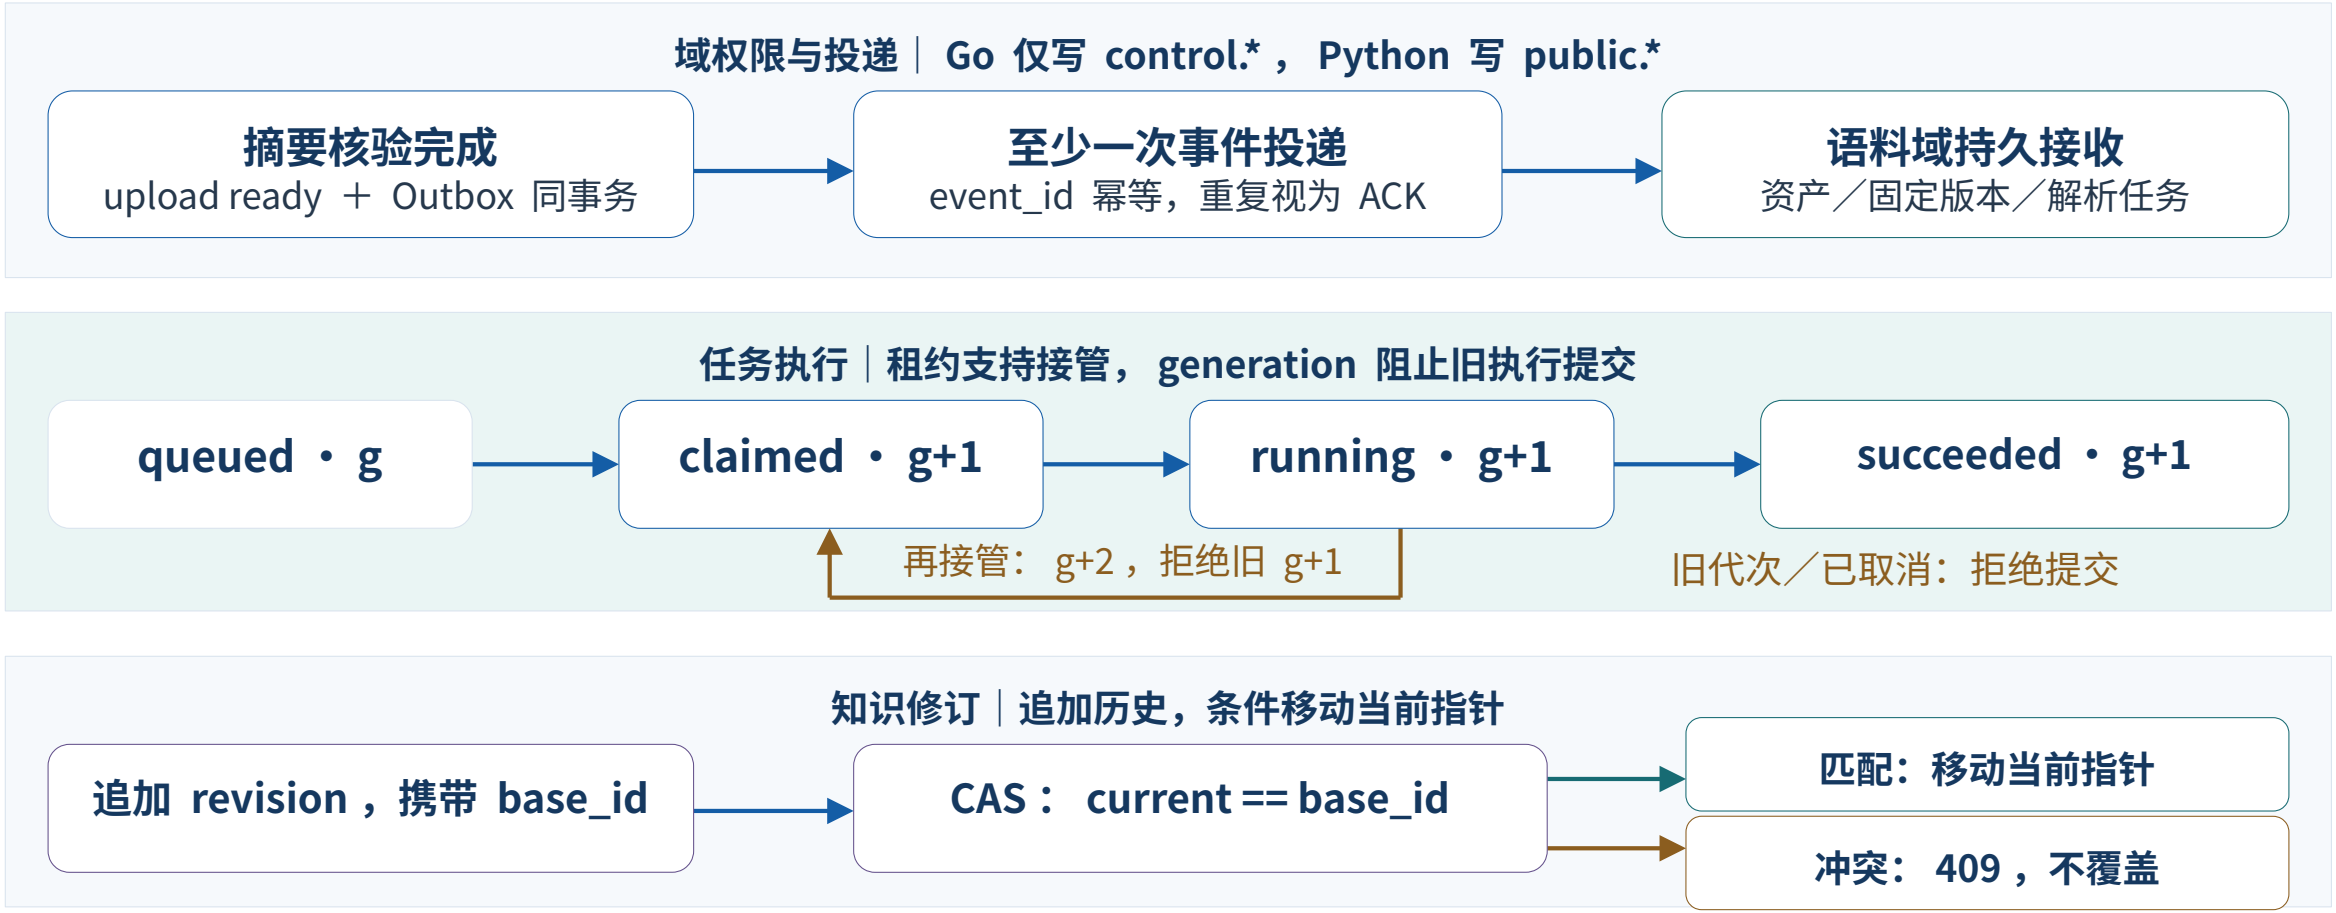
同一工作台，不同的数据执行边界



入口、资料和算力按精确计划协作



故障可恢复，旧执行不能覆盖新状态



创新在可追溯与受控协作的组合

设计问题	项目组合机制	工程价值 ／ 设计代价
工程创新一｜可更新知识与固定证据身份解耦		
更新不能悄悄换出处 原文、生成理解和 检索缓存承担不同身份	**固定版本 + 稳定 Evidence** 源／派生分层，索引可重建 引用与 Wiki 依赖保留绑定	**可追溯、可识别失效** 代价：历史与依赖管理 边界：绑定不证明语义
工程创新二｜数据外发由精确计划约束		
协作不等于默认上云 本地、资料、算力 持有不同权限和能力	**精确计划 + 许可数据边** 两阶段许可、 A 统一提交 结果校验后本机事务导入	**执行位置与数据边可控** 代价：握手、预算、对账 边界：不自动任意互通

复用基础：上游模型／ RAG ／ SQLite ／ PG ／ Outbox ／租约／ CAS ； 创新在工程组合。

实测让改进方向落到具体问题上

既有实测 · 各指标分别解释

指标与范围	配置或任务集合	观察结果
QA 必要原文命中	固定 3 篇 / 6 题， top-4	混合 13/13；关键词 9/13
严格整题通过 · AI 源文审计	C10.2 · 已知开发回归 · 45 任务	34/45
严格整题通过 · AI 源文审计	C10.3 · 已知开发回归 · 12 任务	7/12

改进重点：复杂版面定位 / 多主题覆盖 / 稳定模型服务

结构链路与输出质量分别验证；后续优先补足表格、公式和长主题任务的薄弱样本。

工作台把原文、结构与答案放在同一视图

原始 PDF

解析正文

回答与出处

内容

资源库

文档库

结构化抽取

全文检索

联邦任务

知识 Wiki

实体图谱

开发者

API Key

← 文档库 **M3-Embedding.pdf** 第 1 版 18 页

解析版本 | 校验版本 | 重建索引 | 下载

● 编译完整 ● 代码识别：启发式 ddp-layout/1

原文 | 分块边界 | 1 2 3 4 ••• 18



M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation

Jianlv Chen♣ Shitao Xiao♠† Peitian Zhang♣ Kun Luo♣ Defu Lian♣* Zheng Liu♠*

♣ University of Science and Technology of China ♠ BAAI

stxiao@baai.ac.cn {namespace.pt,luokun695,zhengliu1026}@gmail.com

chenjianlv@mail.ustc.edu.cn liandefu@ustc.edu.cn

Abstract

In this paper, we introduce a new embedding model called **M3-Embedding**, which is distinguished for its versatility in *Multi-Linguality*, *Multi-Functionality*, and *Multi-Granularity*. It provides a uniform support for the semantic retrieval of more than 100 working languages. It can simultaneously accomplish the three common retrieval functionalities: dense retrieval, multi-vector retrieval, and sparse retrieval. Besides, it is also capable of processing inputs of different granularities, spanning from short sentences to long documents of up to 8,192 tokens. The effective training of M3-Embedding presents a series of technical contributions. Notably, we propose a novel self-knowledge distillation approach, where the relevance scores from different retrieval functionalities can be integrated as the teacher signal to enhance the training quality. We also optimize the batching strategy, which enables a large batch size and high training throughput to improve the discriminativeness of embeddings. M3-Embedding exhibits a superior performance in our experiment, leading to new state-of-the-art results on multilingual, cross-lingual, and long-document retrieval benchmarks.[1]

Multi-Linguality | Multi-Functionality | Multi-Granularity

100+ Languages | Dense Retrieval | Sentence-Level

Multi-Lingual | Sparse Retrieval | Passage-Level

Cross-Lingual | Multi-Vec Retrieval | Doc-Level (≤8192)

M3-Embedding

Figure 1: **Characters of M3-Embedding.**

1 Introduction

Embedding models are a critical form of DNN application in natural language processing. They encode the textual data in the latent space, where the underlying semantics of the data can be ex-

dense retrieval, where relevant answers to the query can be retrieved based on the embedding similarity (Karpukhin et al., 2020; Xiong et al., 2020; Neelakantan et al., 2022; Wang et al., 2022; Xiao et al., 2023). Besides, the embedding model can also be applied to other IR tasks, such as multi-vector retrieval where the fine-grained relevance between query and document is computed based on the interaction score of multiple embeddings (Khattab and Zaharia, 2020), and sparse or lexical retrieval where the importance of each term is estimated by its output embedding (Gao et al., 2021a; Lin and Ma, 2021; Dai and Callan, 2020).

Despite the widespread popularity of text embeddings, the existing methods are still limited in versatility. First of all, most of the embedding models are tailored only for English, leaving few viable options for the other languages. Secondly, the existing embedding models are usually trained for one single retrieval functionality. However, typical IR

arXiv:2402.03216v5 [cs.CL] 12 Dec 2025

按页 | Markdown 共 18 页 · 点击段落可在左栏定位

第 1 页

M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation Jianlv Chen♣ Shitao Xiao♠† Peitian Zhang♠ Kun Luo♠ Defu Lian♣∗ Zheng Liu♠∗ ♣ University of Science and Technology of China ♠ BAAI {namespace.pt,luokun695,zhengliu1026}@gmail.com chenjianlv@mail.ustc.edu.cn liandefu@ustc.edu.cn

stxiao@baai.ac.cn

Multi-Linguality Multi-Functionality Multi-Granularity Abstract In this paper, we introduce a new embedding 100+ Languages model called M3-Embedding, which is distin Multi-Lingual

M3-Embedding 支持哪三类检索功能... | 新会话 | 删除

M3-Embedding 支持哪三类检索功能？最长处理多少 token？请分别给出原文出处。

M3-Embedding 支持三类检索功能：稠密检索、多向量检索和稀疏检索。

● 尚未核对



[1] PDF 第 1 页 ● 相关度 68%

Doc-Level (≤8192) provides a uniform support for the semantic re trieval of more than 100 working languages. It can simultaneously accomplish the three com BG...



[2] PDF 第 3 页 ● 相关度 76%

M3-Embedding unifies the common retrieval func tionalities of the embedding model, i.e. dense re trieval, lexical (sparse) retrieval,

三类真实输入，生成三种知识产物

示例① 带出处问答

输入

M3-Embedding 支持哪三类检索功能？最长处理多少 token？请分别给出原文出处。

输出

稠密、多向量、稀疏检索；
8192 token 。

每条主张关联自己的出处

示例② Schema 字段抽取

输入 · 模板说明节选

只抽取固定版本原文明确支持的数值，区分模型输入上限、无监督语料语言数和跨语言对应关系数。

输出

输入上限： 8192 token
无监督语料： 194 种语言
跨语言对应数： 2655

found · verified=false · 附引用

字段值、状态与出处一起返回

示例③ 主题 Wiki

输入

M3-Embedding： 检索功能、输入长度与自知识蒸馏

输出节选 · 选用证据 9/163

M3-Embedding 能够生成通用嵌入，支持稠密检索、稀疏检索和多向量检索。

正文、依赖与修订一同保存

DeepDocParse：从文献检索到知识积累

把一次回答，沉淀为可回查的知识资产

可追溯

固定文献版本
主张连接原文出处

可复核

原文与生成结果分离
保留定位与核对状态

可更新

依赖检查与追加修订
过期引用不会静默漂移

交付形态： Web 工作台 • Electron 桌面客户端 • MCP 工具接口