DeepDocParse 项目技术说明与资料来源

1. 项目定位与总体架构

DeepDocParse面向技术手册与论文，提供检索、问答、字段抽取、知识Wiki及原文证据回查。中心Go控制面与Python语料域经HTTP协作；同一PG集群按control/public分写入权限，原件和解析产物存于对象存储。模型网关负责协议适配及解析临时执行；中心语料任务使用PG持久队列。Electron复用AppShell，本机另有SQLite/FTS与文件工作区。

证据：P3/P12/P13、实现细节与源码索引.md §3/12/13

2. 数据来源与处理

公开应用样例：M3-Embedding，arXiv:2402.03216v5，18页；原件摘要 eb38e53565da260dc1f3d49708f45441936447a7f3c7d7ef025ff62ea3e1e575。作者Jianlv Chen、Shitao Xiao、Peitian Zhang、Kun Luo、Defu Lian、Zheng Liu；CC BY 4.0。来源 https://arxiv.org/abs/2402.03216v5 ，许可https://creativecommons.org/licenses/by/4.0/ 。只展示必要原文及派生结果，原PDF不随包再分发。

历史回归另含Pico、ESP32、Attention等资料；QASPER人类参考题集独立作对照，不混入用户知识库。预处理为直传→摘要核验→解析归一→编译→索引。物理页、块框与固定解析身份贯穿处理。

证据：P2/P5/P6、E23/E22/E05

3. 关键实现机制

DDP-Layout包含8种块类型，表格HTML来自spans[].html；源text不被检索增强覆盖。中心查询内采用RRF=Σ1/(60+rank)，query间轮转、按chunk_id去重；代码精确排名计入两次。QA模型输出claims/unanswered，合法闭合主张才进入SSE；最终引用从持久主张反推。对象数值抽取以Decimal词法核对主出处，found/not_found/error分别返回；当前记录数组不共用该数值见证。

证据：P6–P9、实现细节与源码索引.md

4. 版本知识与受控协作

ResourceVersion固定document_id/parse_job_id，Citation指向Evidence而非可重建Chunk。Wiki冻结有界原文，模型从support-span目录选支持；生成和人工编辑均追加revision，以CAS移动当前指针，依赖变化派生stale。桌面普通内容代理与原生许可桥分离；本机默认CPU文字层与关键词检索。联邦A入口/B资料/C算力按精确计划与资料方继续转发策略协作，返回校验后导入；既有A/B/C记录是同机隔离演练。

证据：P4/P10–P16、源码索引及既有2026-10桌面/联邦记录

5. 实测指标的范围

固定3文档6题、13段必要原文：QA top-4混合命中13/13，受控embedding失败后的关键词命中9/13；rerank关闭。该指标是原文摘录命中。已知开发回归A（C10.2）：严格34/45，分项QA27/30、字段4/7、Wiki3/8；B（C10.3）：7/12，分项6/8、1/2、0/2。严格整题要求完整覆盖且每条主张有自己的充分出处；两组为AI源文审计，不合并。

补充质量背景：历史40项定位页命中26/40、bbox包含15/40，公式密集0/10；QASPER 24题首测 Answer F1=0.2502（答案token重合），Evidence F1=0.1667（证据匹配），不是同一个指标。后续优先复杂版面、多主题覆盖与稳定服务。

证据：P17、E05/E06/E22/E29/E30

6. 三组应用输入与输出

问答输入：“M3-Embedding支持哪三类检索功能？最长处理多少token？请分别给出原文出处。”保存输出为稠密/多向量/稀疏检索及8192 token。字段模板描述输入上限、无监督语料语言数及跨语言对应数，保存输出8192/194/2655。Wiki标题为“M3-Embedding：检索功能、输入长度与自知识蒸馏”，本稿只展示第一段输出节选；原任务选择9/163条证据。

完整修订的第三句“集成学习原理”缺其页证据支持，不作为项目事实结论；原始截图和修订未改写。模板、原始结果、对应来源及对象索引在案例附录。当前生成服务待恢复；保存结果用于项目介绍，正式提交另需有效入口和评审账号。

证据：P18/P19/P20、应用案例与资料说明.md、E18/E23